



SAS[®] Studio

Caso de Uso

SAS and all other SAS Institute Inc. product or service names are registered trademarks or trademarks of SAS Institute Inc. in the USA and other countries. ® indicates USA registration. Other brand and product names are trademarks of their respective companies.

SAS® Studio: Caso de Uso

Copyright © 2024 Copyright. All rights reserved. Printed in the United States of America. No part of this publication may be reproduced, stored in a retrieval system, or transmitted, in any form or by any means, electronic, mechanical, photocopying, or otherwise, without the prior written permission of the publisher, SAS Institute Inc.

Caso de Uso

Caso de Uso-----	3
1. Introducción -----	2
2. Resolución del Caso de Uso -----	7
3. Resultados a Entregar-----	9

1.Introducción

En este caso de estudio, usted resuelve un problema de negocios del mundo real aplicando los conceptos que aprendió en el curso de SAS. Tenga en cuenta que hay numerosas soluciones a este problema, y algunos pueden incluir conceptos que están fuera del alcance del curso.

1.1. Información de fondo

Usted es un usuario SAS con seis meses de experiencia que se encarga de crear informes básicos y mantener programas SAS. Recientemente, ha completado un curso de SAS y su supervisor le ha encargado su primer proyecto.

1.2. Problema de Negocio

Su primer proyecto consiste en preparar y analizar los datos de reclamaciones aeroportuarias de la Administración de Seguridad en el Transporte (TSA) de 2002 a 2017. La TSA es una agencia del Departamento de Seguridad Nacional de Estados Unidos que tiene autoridad sobre la seguridad de los viajeros. Se presenta una reclamación si usted resulta herido o su propiedad se pierde o resulta dañada durante el proceso de control en un aeropuerto.

Para completar su proyecto, siga los requerimientos indicados en el documento. Esto es lo que debe hacer:

- Preparar los datos y responder a las preguntas en cada apartado del análisis.
- Crear un informe en PDF que analice los datos globales y los de un estado especificado dinámicamente.

1.3. Información de los Datos

Los datos que se utilizan son **TSAClaims2002_2017.csv**, que se encuentra en la carpeta Data dentro de la carpeta Workshop. Se creó a partir de lo siguiente:

- Datos de TSA Airport Claims de <https://www.dhs.gov/tsa-claims-data>
- Datos de FAA Airport Facilities de https://www.faa.gov/airports/planning_capacity/passenger_allcargo_stats/passenger/previous_years

El archivo **TSAClaims2002_2017.csv** se creó concatenando cada tabla individual de reclamaciones aeroportuarias de la TSA. Tras la concatenación, los datos se unieron a los de las instalaciones aeroportuarias de la FAA. He aquí algunas notas sobre los datos:

- Todos los datos son públicos y no se garantiza su exactitud.
- La columna **Airport_Code** de los datos de reclamaciones aeroportuarias de la TSA se ha unido con **Location_ID** de los datos de instalaciones aeroportuarias de la FAA. Algunos valores de **Airport_Code** no se corresponden con los valores de **Location_ID**.
- Las columnas de los datos de reclamaciones aeroportuarias de la TSA han cambiado a lo largo de los años. Por este motivo, algunas de las columnas originales se eliminaron de los datos para este estudio de caso.
- La columna **Item_Category** no tiene valores de entrada coherentes a lo largo de los años. Por este motivo, no se limpia esta columna en el estudio de caso.

1.4. Disposición de los Datos

Esta es la información de las columnas de la tabla **TSAClaims2002_2017.csv**.

Columna	Descripción
Claim_Number	Número de cada solicitud. Algunos siniestros pueden tener números de siniestro duplicados, pero información diferente para cada siniestro. Esas reclamaciones se consideran válidas para este estudio de caso. Cualquier fila duplicada debe eliminarse de los datos.
Date_Received	Fecha en la que se recibió la reclamación. Date_Received debe ser posterior a Incident_Date . Rango: De 2002 a 2017
Incident_Date	Fecha en la que se produjo el incidente. Incident_Date debe ser anterior a Date_Received . Rango: De 2002 a 2017
Airport_Code	Código del aeropuerto abreviatura de tres letras.

Columna	Descripción
Airport_Name	Nombre completo del aeropuerto.
Claim_Type	Categoría de la reclamación. Si la reclamación está separada en dos tipos por una barra oblicua, Claim_Type es el primer tipo. Por ejemplo: <i>Passenger Property Loss/Personal Injury</i> se considera <i>Passenger Property Loss</i>. Valores posibles (14): • <i>Bus Terminal</i> • <i>Complaint</i> • <i>Compliment</i> • <i>Employee Loss (MPCECA)</i> • <i>Missed Flight</i> • <i>Motor Vehicle</i> • <i>Not Provided</i> • <i>Passenger Property Loss</i> • <i>Passenger Theft</i> • <i>Personal Injury</i> • <i>Property Damage</i> • <i>Property Loss</i> • <i>Unknown</i> • <i>Wrongful Death</i>
Claim_Site	Localización aeroportuaria del siniestro. Valores Posibles (8): • <i>Bus Station</i> • <i>Checked Baggage</i> • <i>Checkpoint</i> • <i>Motor Vehicle</i> • <i>Not Provided</i> • <i>Other</i> • <i>Pre-Check</i> • <i>Unknown</i>
Item_Category	Tipo de artículos que se han presentado en la reclamación. Los valores de entrada para Item_Category difieren en función del año de los datos. Debido a que la coherencia varía, no es necesario limpiar esta columna para el caso práctico.

Close_Amount	Importe en dólares por el que se cerró una reclamación.
Columna	Descripción
Disposition	La liquidación final del siniestro. Valores Posibles (10): • <i>*Insufficient</i> • <i>Approve in Full</i> • <i>Closed:Canceled</i> • <i>Closed:Contractor Claim</i> • <i>Deny</i> • <i>In Review</i> • <i>Pending Payment</i> • <i>Received • Settle</i> • <i>Unknown</i> <i>*Insufficient</i> es el valor de los datos brutos.
StateName	Nombre del estado del aeropuerto asociado (por ejemplo, NEW YORK). Requisitos: Los valores deben estar en mayúsculas. (Los datos originales están en mayúsculas).
State	Código de estado del aeropuerto asociado. Se trata de la abreviatura estándar de dos letras utilizada por la oficina de correos para los estados y territorios de EE.UU. (por ejemplo, IL, PR, CQ). Requisitos: Los valores deben ir en mayúsculas (por ejemplo, NY).
County	Aeropuerto asociado al nombre del condado (o distrito) (por ejemplo, Cook).
City	Nombre de la ciudad del aeropuerto asociado (por ejemplo, CHICAGO).

1.5. Requerimientos

Para preparar y analizar los datos, siga los requisitos a continuación tanto para datos como el informe. Seguidamente en el punto 2 se darán los pasos más detalladamente:

1.5.1. Datos

Importe el archivo de datos brutos **TSAClaims2002_2017.csv**. El archivo se encuentra en la carpeta Data dentro de la carpeta Workshop.

- Los datos finales deben estar en la librería permanente tsa, y el conjunto de datos debe llamarse **claims_cleaned**.
- Deben eliminarse del conjunto de datos todos los registros duplicados.
- Todos los valores *missing* en las columnas **Claim_Type**, **Claim_Site** y **Disposition** deben cambiarse a *Unknown*.
- Los valores de las columnas **Claim_Type**, **Claim_Site** y **Disposition** deben seguir los requisitos de la disposición de datos.
- Todos los valores de **StateName** deben ir en mayúsculas.
- Todos los valores de **State** deben estar en mayúsculas.
- Cree una nueva columna llamada **Date_Issues** con un valor de *Needs Review* para indicar que una fila tiene un problema de fecha. Los problemas de fecha consisten en lo siguiente:
 - un valor a *missing* para **Incident_Date** o **Date_Received**
 - un valor de **Incident_Date** o **Date_Received** fuera del intervalo de años predefinido de 2002 a 2017
 - un valor de **Incident_Date** posterior al valor de **Date_Received**.
- Elimine las columnas **Country** y **City**.
- Las divisas deben formatearse permanentemente con un signo de dólar e incluir dos decimales.
- Todas las fechas deben formatearse permanentemente con el estilo 01JAN2000.
- Las etiquetas permanentes deben asignarse a las columnas sustituyendo los guiones bajos por un espacio.
- Los datos finales deben ordenarse en orden ascendente por **Incident_Date**.

1.5.2. Informe

El informe final de PDF se deben excluir todas las filas con problemas de fecha en el análisis y responder a las siguientes preguntas:

1. ¿Cuántos problemas de fechas hay en los datos globales?
2. ¿Cuántos siniestros por año de **Incident_Date** hay en los datos globales? Asegúrese de incluir un gráfico.

Por último, un usuario debe poder introducir dinámicamente un valor de estado (**State**) específico y responder a las siguientes preguntas:

1. ¿Cuáles son los valores de frecuencia de **Claim_Type** para el estado seleccionado?
2. ¿Cuáles son los valores de frecuencia de **Claim_Site** para el estado seleccionado?
3. ¿Cuáles son los valores de frecuencia de **Disposition** para el estado seleccionado?
4. ¿Cuál es la media, el mínimo, el máximo y la suma de **Close_Amount** para el estado seleccionado? Redondee al número entero más próximo.

2. Resolución del Caso de Uso

Como guía de resolución a continuación se indican los pasos a seguir en el análisis.

Se recuerda que la documentación oficial es [SAS Documentation](#).

2.1. Acceso a los Datos

- 2.1.1. Importar **TSAClaims2002-2017.csv** en la librería con nombre **tsa**. Por de nombre a la tabla **ClaimsImport**.

2.2. Exploración de los Datos

- 2.2.1. Previsualiza las 20 filas y examina la parte descriptiva de los datos **tsa.ClaimsImport**. ¿Cuántas observaciones hay?
- 2.2.2. Explora las siguientes columnas para ver si se necesita algún ajuste usando la información y disposición de los datos: **Claim_Site**, **Claim_Type**, **Disposition**, **Date_Received**, **Incident_Date**.
- 2.2.3. ¿Qué problemas se ven?

2.3. Preparación de los Datos

- 2.3.1. Elimina por completo las filas duplicadas de la tabla **tsa.ClaimsImport** y crea una tabla llamada **tsa.Claims_NoDups**.
Note: Algunos valores de **Claim_Number** son duplicados, pero hay valores diferentes en otras columnas. Considera estos como válidos.
¿Cuántas observaciones hay en **tsa.Claims_NoDups**?
- 2.3.2. Ordena la tabla **tsa.Claims_NoDups** por la columna **Incident_Date**.
- 2.3.3. Limpia la columna **Claim_Site** en la tabla de **tsa.Claims_NoDups** reemplazando los valores missing por *Unknown*. Guarda los resultados en una nueva tabla llamada **tsa.Claims_Cleaned**.
- 2.3.4. Modifica el DATA step anterior para que además limpie la columna de **Disposition** reemplazando los valores missing por *Unknown*, eliminando el espacio del valor *Closed: Canceled*, y reemplazando *losed: Contractor Claim* por *Closed: Contractor Claim*.
- 2.3.5. Modifica de nuevo el paso DATA anterior para que también limpie la columna **Claim_Type** reemplazando los missing por *Unknown*, *Passenger Property Loss/Injury* y *Passenger Property Loss/Injur* por *Passenger Property Loss*, y *Property Damage/Personal Injury* por *Property Damage*.
- 2.3.6. Modifica el paso DATA para que además convierta los valores de **State** a mayúscula y **StateName Columns** a propercase.
- 2.3.7. Modifica el paso DATA anterior para que también cree una nueva columna que identifique las filas con días problema. Llama a la nueva columna **Date_Issues** y asigna un valor de *Needs Review* para cada fila donde el valor de **Incident_Date** o el de **Date_Received** está a missing, es anterior a 2002, o posterior a 2017, o en aquellos que el valor de **Incident_Date** se posterior al **Date_Received**.

- 2.3.8. Modifica el paso DATA anterior para que además añada labels permanentes y formatos a cada columna. Los labels tienen que tener propercasing y espacios entre palabras. Las columnas de **Incident_Date** y **Date_Received** deberán formatearse de la siguiente manera: 01JAN1960. La columna **Close_Amount** deberá formatearse con el signo de \$, comas y 2 decimales.
- 2.3.9. Finalmente actualiza el paso DATA anterior eliminando las columnas de **County** y **City**.

2.4. Análisis de los Datos

Responda a las siguientes preguntas a nivel estatal y empresarial en general. **Debe excluir todas las filas con problemas de fechas** en el análisis.

- 2.4.1. ¿Cuántos problemas de fechas hay en los datos globales?
- 2.4.2. ¿Cuántos siniestros por año de **Incident_Date** hay en los datos globales? Incluya un gráfico.
- 2.4.3. ¿Cuáles son los valores de frecuencia para **Claim_Type**, **Claim_Site** y **Disposition** para el estado seleccionado?
- 2.4.4. ¿Cuál es la media, el mínimo, el máximo y la suma de **Close_Amount** para el estado seleccionado? Redondee al número entero más próximo.

2.5. Exportación de los Datos

- 2.5.1. Exporte los resultados a un único archivo PDF denominado ClaimReports_nombre_apellido1_apellido2 con el estilo que prefiera.
- 2.5.2. Personalice las etiquetas de los procedimientos en el informe final.

3.Resultados a Entregar

Los resultados a entregar requeridos para esta parte serían de 2 tipos:

1. Un fichero Zip **ClaimsProgram_Nombre_Apellido1_Apellidos**: con el los flujos usados, bien documentado y contestando a las diferentes preguntas de los apartados en diferentes comentarios.
2. **ClaimsReports_Nombre_Apellido1_Apellido2.pdf** (generado en 2.5 en el que se muestre el análisis realizado anteriormente en 2.4 y pasos anteriores)